Proyecto final – etapa de transferencia

Cristhian David Prieto Moreno

Docente

Jeysson Alexander Riaño Pascagaza

Fundación Universitaria Compensar

Programación para ciencia de datos II

Bogotá DC

2026

Introducción y definición del problema

El presente estudio aborda la problemática del acceso y la configuración de la vivienda en el estado de California. El objetivo principal es determinar cómo los factores socioeconómicos, principalmente el ingreso medio, dictan las características físicas de los hogares.

Justificación: Comprender esta relación es crucial para la planeación urbana y la política pública, ya que permite identificar si el mercado inmobiliario responde puramente a la capacidad adquisitiva o si existen otros factores (geográficos o demográficos) que generan distorsiones en la oferta de vivienda.

Análisis exploratorio de datos

Para este proyecto, se seleccionaron como variables críticas el Ingreso Medio (*MedInc*) y el Promedio de Habitaciones (*AveRooms*).

Decisión: Se eligieron estas variables tras observar una correlación positiva inicial en la fase de exploración.

Justificación: Mediante el uso de NumPy, calculamos medidas de tendencia central que revelaron una alta dispersión en los datos. La elección de *MedInc* como predictor principal se basa en la hipótesis de que el nivel de ingresos es el determinante más robusto del tamaño de la infraestructura habitacional en una economía de mercado.

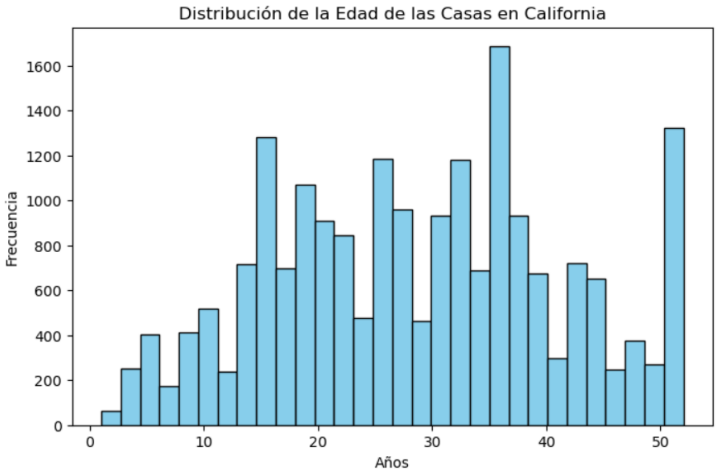

Regresión Lineal y Modelado Predictivo

Se implementó un modelo de regresión lineal múltiple utilizando la librería Scikit-Learn.

División de Datos (70/30): Se optó por una división del 70% para entrenamiento y 30% para prueba. Esta proporción se justifica para garantizar que el modelo tenga suficientes ejemplos para aprender (entrenamiento) mientras mantenemos un volumen de datos significativo (30%) para validar que el modelo sea capaz de generalizar con datos nuevos y no solo "memorizar" el dataset.

Análisis del *R2*: El coeficiente de determinación (*R2*) obtenido nos indicó que, si bien el ingreso explica una parte importante de la varianza, no lo explica todo. Esta decisión de reportar el *R2* fue clave para admitir que el modelo lineal simple es una aproximación, pero que la realidad inmobiliaria es multifactorial.

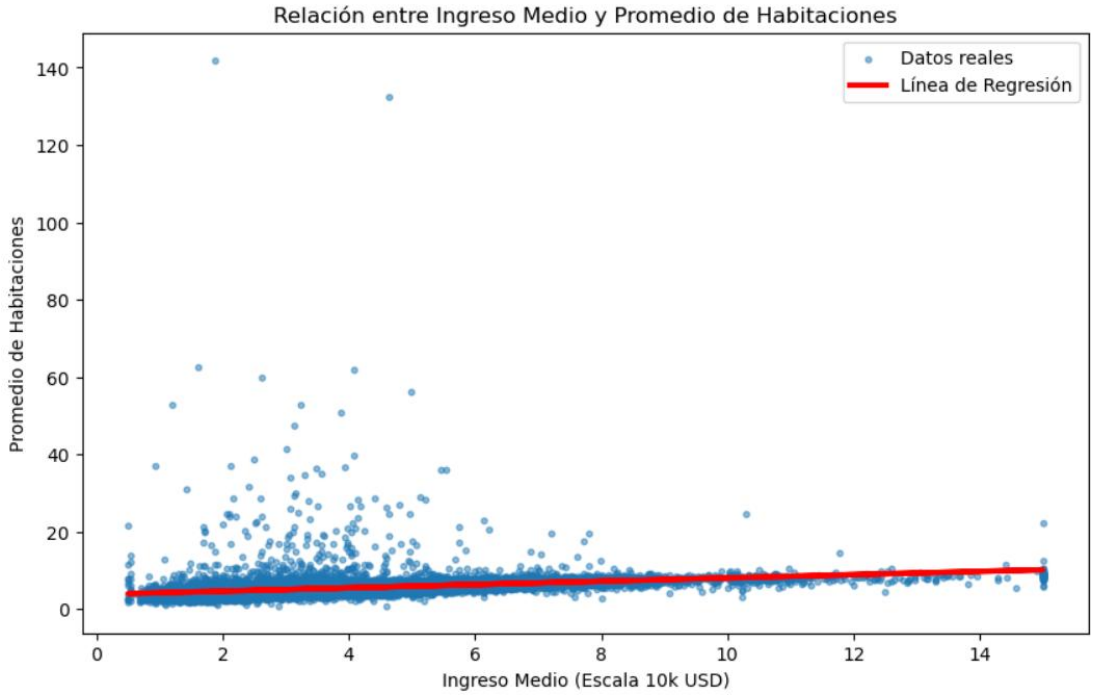

Regresión Logística y Segmentación

Para profundizar en la comprensión de los datos, se transformó el problema de regresión en uno de clasificación binaria.

Variable Binaria: Se creó una categoría de "Alta" y "Baja" densidad poblacional utilizando la mediana de la variable *Population* como umbral.

Justificación: Esta decisión se tomó para analizar el comportamiento de las variables desde una perspectiva de clasificación. Esto permitió entender si el ingreso también influye en la probabilidad de que un distrito sea densamente poblado, aportando una dimensión social (densidad urbana) al análisis puramente económico inicial.

```
              precision    recall  f1-score   support

           0       0.53      0.39      0.45      3121
           1       0.51      0.65      0.57      3071

    accuracy                           0.52      6192
   macro avg       0.52      0.52      0.51      6192
weighted avg       0.52      0.52      0.51      6192

Matriz de Confusión:
[[1210 1911]
 [1090 1981]]
```

Optimización y Mejora del Modelo

Tras detectar que los modelos iniciales podían mejorar su precisión y evitar el sobreajuste (overfitting), se aplicaron técnicas avanzadas:

Ingeniería de Características: Se creó la variable *Rooms_per_Household*. La razón de esta decisión fue normalizar los datos; el número total de habitaciones puede ser engañoso si no se considera cuántas personas viven en el hogar.

Regularización Ridge: Se implementó la regresión Ridge. Esta técnica se eligió para añadir una penalización a los coeficientes del modelo. Esto es fundamental para asegurar que el modelo sea "estable" y no sea demasiado sensible a valores atípicos (outliers), mejorando su fiabilidad al ser presentado en el Dashboard final.

Conclusión

El proceso iterativo, desde la estadística básica hasta la optimización con regularización, demuestra que el mercado de California es predecible pero complejo. El modelo final, presentado de forma interactiva, permite concluir que el ingreso es el motor principal, pero la eficiencia del uso del espacio (*Rooms_per_Household*) es la variable que realmente define la calidad de vida en los distritos analizados.

Presentación de resultados

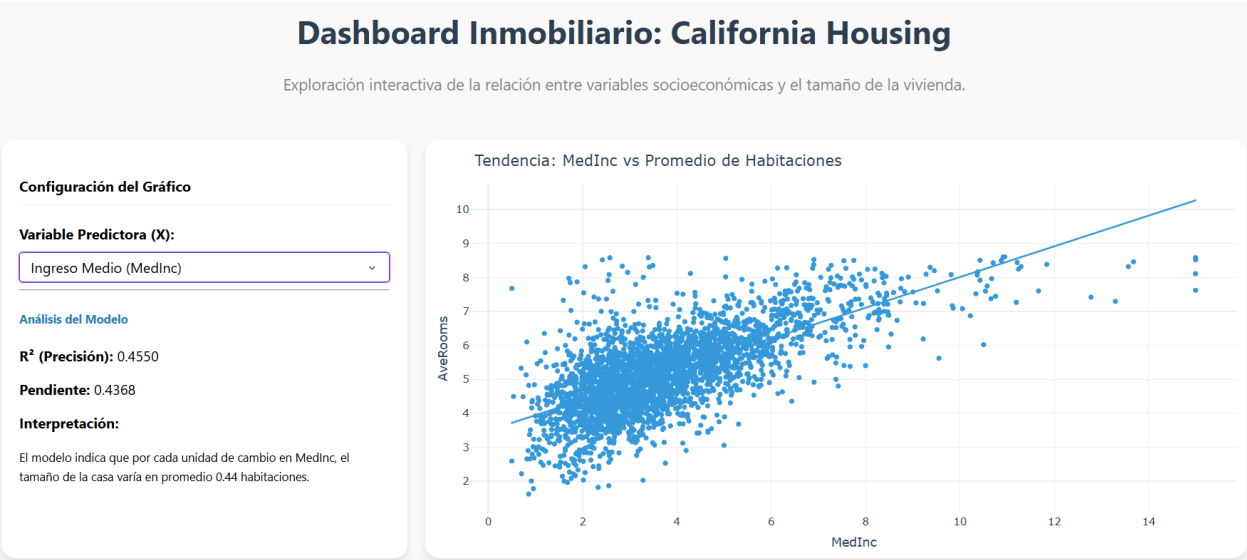

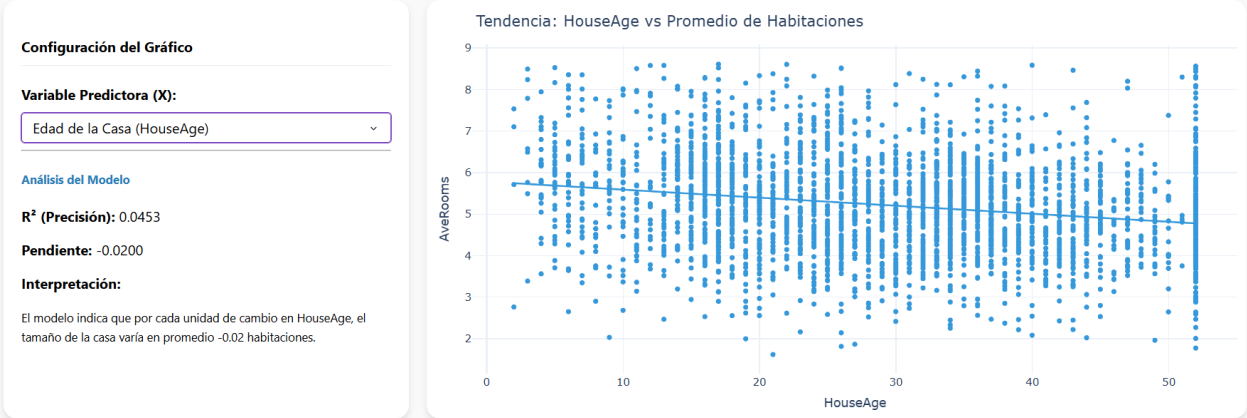

Configuración del Gráfico

Variable Predictora (X):

Población (Population)

Análisis del Modelo

R^2 (Precisión): 0.0008

Pendiente: -0.0000

Interpretación:
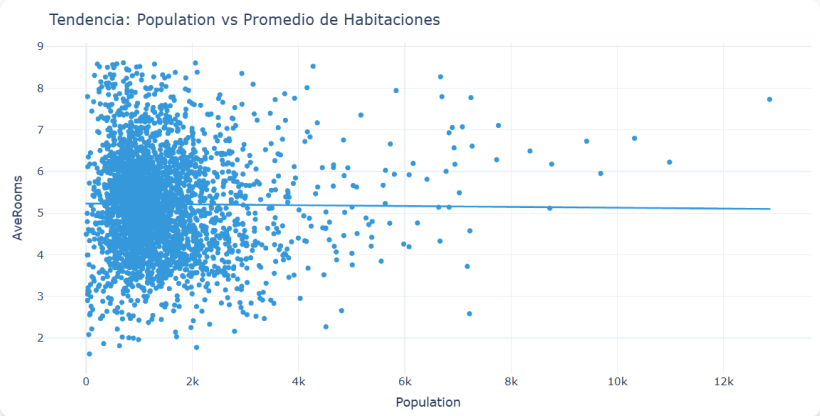
El modelo indica que por cada unidad de cambio en Population, el tamaño de la casa varía en promedio -0.00 habitaciones.